

同濟大學

TONGJI UNIVERSITY

毕业设计（论文）

课题名称 基于城市街景图的道路设施环境安全评价

副标题

学 院

土木工程学院

专 业

土木工程

学生姓名

徐晨昊

学 号

2054153

指导教师

日 期

2025 年 5 月 29 日

基于城市街景图的道路设施环境安全评价

摘要

随着城市化进程加速，道路安全评价成为提升交通治理效能的关键课题。本研究基于加州北部的交通事故数据与旧金山路网数据，使用街景图像提取、YOLO 语义分割与地理信息系统方法，构建了从数据融合、机器学习建模到空间风险可视化的完整技术框架。结果表明，XGBoost 模型在对事故严重程度的分类任务中表现最优，其解释性分析表明了隔离设施与信号灯等道路基础设施是影响事故严重程度的核心特征，且证实了优化道路基础设施的设计与维护对减少交通事故发生具有显著作用。最终，本研究以旧金山为例应用该技术框架，构建出旧金山地区的城市道路设施安全空间。本研究推进了道路安全评价体系的建设，为道路设施环境的设计与维护提供了兼具理论创新与实践价值的解决方案。

关键词：街景图像（SVI），道路安全评价，机器学习，语义分割

Safety Evaluation of Road Facilities Surroundings Based on Urban Street View Imagery

ABSTRACT

With the acceleration of urbanization, road safety evaluation has become a key issue in improving the efficiency of traffic governance. This study is based on traffic accident data from northern California and data from the San Francisco Mountain Road network. Using methods like street view imagery extraction, YOLO semantic segmentation, and geographic information system, a complete technical framework was constructed from data fusion, machine learning modeling to spatial risk visualization. The results indicate that the XGBoost model performs the best in the task of classifying the severity of accidents. Its explanatory analysis shows that road infrastructure is the core feature that affects the severity of accidents, and confirms that optimizing the design and maintenance of road infrastructure such as separators and traffic lights has a significant effect on reducing traffic accidents. Finally, this study applied the technology framework to San Francisco as an example to construct a safe space for urban road facilities in the city area. This study has promoted the construction of a road safety evaluation system, providing a solution that combines theoretical innovation and practical value for the design and maintenance of road facilities and environments.

Key words: Street View Imagery(SVI), Road Safety Assessment, Machine Learning, Semantic Segmentation

目 录

1	引 言	1
1.1	研究背景	1
1.2	研究目的与意义	1
1.3	文献综述	1
1.3.1	国外研究现状	1
1.3.2	国内研究现状	2
1.3.3	文献评述	3
1.4	研究内容与方法	3
1.4.1	研究内容	3
1.4.2	研究方法概览	4
2	理论研究	5
2.1	语义分割	5
2.2	模型算法	6
2.2.1	地理加权回归	6
2.2.2	逻辑回归	7
2.2.3	决策树	7
2.2.4	随机森林	8
2.2.5	XGBoost	9
2.3	分类问题在机器学习中的评价指标	10
2.4	克里金插值	11
3	多维交通事故数据与街景图像的融合与预处理	12
3.1	数据来源与相关说明	12
3.2	街景图像	13
3.2.1	街景图像获取	14
3.2.2	语义分割建模	14
3.2.3	预测后处理	16
3.3	多维数据融合与特征工程	17
3.3.1	数据集成与特征体系构建	17
3.3.2	变量相关性分析	18
4	基于机器学习的交通安全因子与事故严重程度关系建模	20
4.1	模型的训练与预测	20
4.1.1	地理加权回归	20
4.1.2	逻辑回归	21
4.1.3	随机森林	21
4.1.4	决策树	21
4.1.5	XGBoost	21
4.2	模型性能比较	22
4.3	解释性分析	24
4.3.1	变量影响模式分析	24
4.3.2	SHAP 分析	28
5	基于城市基础设施的城市道路设施安全空间分析 —— 以旧金山为例	31
5.1	数据采集与处理	31
5.2	目标变量预测	32
5.3	安全空间可视化	32

线

1 引言

1.1 研究背景

随着城市化进程的加速，城市交通环境的复杂性不断增加。城市发展对道路安全性提出了更高的要求。城市道路安全性是衡量市民生活质量和社会稳定的重要指标，而道路基础设施的设计与布局直接关系到交通事故的发生概率及其后果的严重程度。基础设施的不完善，如标识缺失、信号灯故障、道路障碍物等，都会显著增加交通事故的风险。特别是在高等级道路等复杂交通环境，合理设计基础设施对于降低事故发生率、减轻事故严重程度至关重要。

现有研究已经对交通事故数据、道路基础设施信息进行了深入探讨，并取得了一定的成果。然而，对于街景图像数据在道路安全评价中的应用和整合仍存在不足。因此，本研究将聚焦于基于城市街景图的道路设施环境安全评价，试图为城市交通安全管理提供新的视角和方法。

1.2 研究目的与意义

道路交通安全是城市交通系统运行的核心问题，直接关系到人民群众生命财产安全和城市交通运行效率。近年来，随着我国城市化进程的加速推进，城市道路网络不断扩展，交通环境日趋复杂。现有研究多聚焦于交通事故数据统计和道路几何参数分析，对城市道路环境多维度特征的系统性研究仍显不足。建立科学完善的道路安全评价体系，对于预防交通事故、优化道路设计及提升交通管理水平具有重要的现实意义。

传统道路安全评价主要依赖人工现场调查和交通流量监测数据，存在数据采集成本高、时空连续性差等问题。本文引入街景图像分析技术，通过谷歌地图 API 获取覆盖研究区域的街景图像数据。相较于传统方法，街景图像具有三大优势：其一，数据覆盖范围广，可获取道路断面全要素信息；其二，图像分辨率达到像素级，可清晰识别交通标志标线等设施；其三，支持历史数据回溯，为安全评估提供时间序列分析基础。这种新型数据源的运用，为构建多维度道路安全评价体系提供了技术支撑，成为城市环境评价研究中重要的新数据源^[1]。

道路安全水平不仅受基础设施影响，还与道路环境密切相关。气象条件会通过改变驾驶员视觉认知和行车行为影响交通安全。研究表明，不利气象条件是诱发交通事故的主要客观因素之一，交通运行安全和高效管理需求对气象条件的敏感性和依赖性日益增强^[2]。因此，将气象环境因素纳入考虑对事故分析的完整性与全面性有重要意义。

综上所述，本研究的具体意义体现在三方面：第一，建立融合街景图像数据与气象参数的多维数据分析框架，拓展了道路安全研究的数据维度；第二，提出基于深度学习的环境要素提取算法，拓展了基于计算机视觉的定量分析工具库；第三，形成可迁移的安全评估指标体系，为学界深化道路安全认知和政策部门优化基础设施规划提供多维度的理论支持和实践指引。

1.3 文献综述

1.3.1 国外研究现状

在理论方向，国外关于安全评价的研究主要集中在行人碰撞风险上。Wier^[3]等人开发了一种

多变量的区域级回归模型,用于预测与土地利用开发和交通规划决策相关的车辆-行人伤害碰撞的区域级变化。Miranda-Moreno^[4]等人建立了两方程建模框架,研究建成环境对信号化交叉口的行人活动和车辆-行人碰撞频率的影响。基于这些研究,Hu^[5]等人发现,通过从街景图像中提取链接级行人暴露量能够比区域级测量更好地拟合模型,并且行人设施对行人碰撞频率和严重性有不同的影响。

在街景图像分析方面,Andrew G. Rundle^[6]等人探讨了使用 Google 街景图进行邻里环境审计的可行性,展示了街景图像在数据分析中的潜力。Filip Biljecki^[7]等人进行了全面的文献综述,回顾了街道视角图像在多个领域中的应用。Yujun Hou^[8]等人建立了一个多元素的分类集,这些元素涉及图像质量、地理信息和元数据等,用于描述和评估街景图像的质量。

对于低等级道路在不利天气条件下的安全评价,Tian^[9]等人使用评估点方法计算得到了风险值,分析了隐藏危险路段对交通安全的影响,并针对此提供了控制措施。

在应用层面,Philip^[10]等人使用机器学习技术实现了车辆和道路基础设施层面事件的自动检测,此提高交通安全的技术方法很有启发性。

总体来看,国外研究普遍认为道路设施环境安全评价在交通规划和公共健康领域具有重要作用,并为实际应用提供了有力支持。然而,Hu^[5]等人指出,现有研究仍存在局限性,如街景图的时空覆盖范围有限,未来需进一步研究以拓展其在不同环境和条件下的应用。

1.3.2 国内研究现状

胡启洲等人^[11]最先提出建立基于时空分布的城市道路交通安全的测度指标体系和模型,以评估和控制城市道路交通安全。他利用价值函数构建城市道路交通安全的测度模型,有效控制了系统中的人的不安全行为,使城市道路网络系统的效益达到最佳化。他通过量化的方式来评估道路设施环境的安全性能,对于后续的研究是极具启发性的。

在事故鉴别方法方面,崔洪君等人^[12]提出一种基于交通事故间距分布特征的事故黑点鉴定新方法,避免了传统方法中路段划分的随意性。蒋宏^[13]等人采用非参数核密度估计模型描述交通事故点的空间二维分布,通过空间自相关分析实现了路段(交叉口)事故多发点的有效方案。王海和李瑞敏^[14]探讨了如何使用缓冲区分析方法鉴别道路交通事故多发点。张琦^[15]等人则从大规模事故点云数据中识别事故黑点,定量评估了道路开口对临近交叉口交通安全的影响。

在道路交通安全风险评估方面,洪皓珏^[16]提供了一种综合多源数据进行评估的方法,他通过梯度提升树、随机森林和线性回归技术建立缺失数据预测模型,利用基于 Hash 树的 Apriori 算法挖掘交通安全风险与各交通因素之间的相关关系,以及循环神经网络和长短时记忆循环神经网络建立交通安全风险预测模型。寇敏^[17]等人则对各种风险评估方法作了比较总结,包括安全风险理论分析法、系统安全分析法、大数据与人工智能分析方法等。

在街景图像分析方面,张丽英^[18]等人指出街景图像覆盖范围广、数据量大、交通信息丰富的优点,并综述了街景图像在城市环境评价中的研究进展,包括基于图像分析、统计分析、人工智能和空间分析的方法,证明了街景图像用于深度学习的可行性。为了提升街景图像识别的精度,吴炳剑^[19]等人提出了一种结合生成对抗网络和混合注意力机制的街景图像语义分割模型以助于分割小目标物体;李健^[20]等人则利用 ResNet50 作为骨干网络,结合递归门控卷积模块和金字塔

池化模块，提高了识别复杂街景图像中物体间相互作用的准确率。

在应用层面，杨文锦和刘俐珂^[21]在安全测度模型的基础上研发了一种行车安全隐患监测与警示系统装置。陈熙^[22]等人提出了对动态隐患目标识别预警的系统应用。他们的技术方法和实施效果为后续研究提供了参考与案例分析。

总体来说，国内研究普遍认为道路设施环境安全评价对于道路交通安全领域具有广泛应用前景。胡启洲^[11]等人指出，尽管国内研究在理论和实践上都取得了一定成果，但与国外相比仍有一定差距，特别是在道路交通安全评价方法的系统性研究方面，未来需要进一步深化。寇敏^[17]等人也强调了多维度数据融合等方向的重要性。

1.3.3 文献评述

纵观交通安全评价现有的研究成果，国内外学者对于交通安全风险评估有着全面而深入的剖析。综合来看，他们不仅为风险评估提供了重要方法与思路，也体现了此类问题在整体上面临着诸多可能性，这主要源于其因素的复杂性与多样性。国外学者将街景图应用到行人碰撞风险控制中，且已经取得一定成果，尽管国内学者已对多种风险评估方法开展了深入的研究，但将城市街景图引入道路设施环境安全评价模型构建的相关研究仍较为缺乏。此外，随着科技进步，道路设施环境譬如城市交叉口越发复杂，数据种类繁多，而先前研究的方法主要集中在单一数据类型分析，对于多类型、多维度数据融合下的道路安全综合评价体系的探讨仍显不足。针对这些不足，本文将提取多维度事故数据与街景图相结合，并以深度学习赋能安全因子建模，推动城市道路设施安全空间的分析。

1.4 研究内容与方法

1.4.1 研究内容

（1）收集交通事故数据并整理成结构化数据，包括事故地理位置、事发气象条件、严重程度等级等。结合事故 GPS 位置，使用谷歌 SVI API 获取对应的城市街景图像。这些图像将作为后续分析的数据基础。为了确保数据的统一性和可用性，需要对收集到的数据进行预处理，包括去噪、标准化和格式转换等，为深度学习模型的输入提供准确一致的数据。

（2）利用深度学习方法分析街景图像，识别潜在交通安全因子（如标志牌、信号灯、车道线等）。通过语义分割提取图像中的关键元素，并与事故严重程度作为安全性评价指标进行关联。构建多类型变量的算法模型，揭示交通安全因素与事故严重度之间的关系，量化不同安全因素对事故严重程度的影响，为交通安全优化提供数据支持和决策依据。

（3）基于前期建立的安全性评价模型，对城市道路基础设施环境的安全性进行评估，通过随机选取道路采样点提取关键设施特征，并计算出每个采样点的危险性评分。结合地理信息系统（GIS）技术，通过空间插值构建基于城市基础设施环境评价的城市道路设施安全空间，并通过空间分析展示城市交通安全的分布和差异。最终量化不同区域的道路安全状况，为城市交通安全管理提供量化的参考依据。

1.4.2 研究方法概览

本研究遵循的三个阶段如图 1.1 所示：首先，整合事故原始数据（包括严重程度、气象条件及经纬度坐标），通过开放地图平台批量获取事故地点的街景图像。利用语义分割模型解析图像中的基础设施要素，量化其面积占比，结合气象观测值构建自变量特征集，并以事故严重程度作为目标变量。随后，选用地理加权回归、XGBoost、逻辑回归、随机森林、决策树五种算法模型构建危险系数评估模型，通过随机网格搜索与贝叶斯优化进行参数调优，基于模型性能比较筛选最优模型，并通过解释性分析揭示关键因子的贡献度。最终，基于最优模型预测旧金山路网随机点的安全风险值，通过克里金空间插值生成城市级事故热力图，结合 GIS 可视化技术展现高风险区域的空间分布特征。整个流程采用模块化设计，在数据融合、模型构建与空间分析环节形成闭环验证体系。




图 1.1 技术路线流程图

2 理论研究

2.1 语义分割

语义分割（Semantic Segmentation）在本研究中用于分割各采样点的街景图像，从而实现将街景图像数据量化为各道路设施标签的街景图面积占比。它作为计算机视觉领域的核心任务之一，其目标是对输入图像中的每个像素进行分类，将其映射到预定义的语义类别（如道路、天空、绿化等），从而实现像素级的场景解析。传统方法依赖手工设计特征和阈值分割，但受限于复杂场景的多样性及特征表达能力。随着深度学习的发展，基于卷积神经网络（CNN）的端到端模型成为主流：FCN 通过反卷积层恢复空间分辨率，实现任意尺寸输入的像素级预测；U-Net 引入编码器-解码器结构与跳跃连接，保留多尺度特征以提升边缘精度，在医学影像分割中表现突出。针对复杂场景，研究者进一步提出多尺度特征融合^[23]及上下文建模^[24]以增强语义一致性。该技术虽已得到广泛应用，但仍面临小目标分割困难及标注数据依赖性强等挑战。

本研究采用基于 YOLOv11 的语义分割模型。YOLOv11 是 Ultralytics 推出的新一代实时目标检测与分割模型，其架构如图 2.1 所示。




图 2.1 YOLOv11 架构图

图中，骨干网络的 Conv 代表标准卷积层，用于基础特征提取，包含卷积核、批归一化（BN）和激活函数（如 SiLU）；C3k2 代表跨阶段卷积模块，由 3 个卷积层构成（k2 即 kernel=2），整合 CSPNet 思想，通过残差连接提升梯度流动效率；C2PSA 代表核心创新模块，结合跨阶段部分网络（CSP）与空间注意力机制，增强特征选择能力（如聚焦小目标）。颈部网络中，Upsample 代表上采样操作，通过插值或转置卷积放大特征图尺寸，用于恢复高分辨率细节（如双线性插值）；Concat 将不同层级的特征图按通道维度融合。头部网络中，Detect 代表检测与分割头，输出分类置信度、边界框坐标及像素级分割掩膜。整体框架通过 C2PSA 强化小目标特征，多级 Concat 融合多尺度信息，最终 Detect 模块实现端到端检测与分割。

YOLOv11 在语义分割中通过架构优化，改进 CSPNet 主干网络、融合通道与空间注意力的 C2PSA 模块，辅以多尺度特征融合机制，显著提升了小物体和边界的识别精度。对比 YOLOv8，

该模型在参数量减少 22% 的同时，COCO 数据集分割任务 mAP@0.5 提升至 0.795，推理速度达 2.4ms/帧，支持各种工业场景。轻量化解码器和跨平台部署能力使之可通过预训练模型快速实现像素级分割。

在本研究中，通过卷积神经网络提取街景图像的多尺度特征，结合跳跃连接（skip-connection）实现浅层细节与深层语义信息的融合。模型的输出层采用 Softmax 函数计算各像素属于基础设施类别的概率，最终生成像素级分割掩膜。通过量化分割结果中道路标志、护栏等要素的面积占比，得到事故风险分析的特征指标。

2.2 模型算法

2.2.1 地理加权回归

地理加权回归（GWR，Geographically Weighted Regression）在本研究中用于揭示变量关系随地理位置的变化，从而与机器学习模型比较。它是一种处理空间异质性的传统局部回归模型，其核心在于将空间位置嵌入回归方程，允许回归系数随地理坐标动态变化^[25]。模型形式为：

$$y_i = \beta_0(u_i, v_i) + \sum_{k=1}^p \beta_k(u_i, v_i)x_{ik} + \varepsilon_i \quad i = 1, 2, \dots, n \quad (2.1)$$

其中 (u_i, v_i) 为第 i 个采样点的经纬度坐标， $\beta_k(u_i, v_i)x_{ik}$ 为空间变参数。

空间权重矩阵的构建是 GWR 的关键，常用方法包括高斯核函数和双平方函数。前者的权重随距离呈指数衰减，带宽参数为 b 时的公式为：

$$w_{ij} = \exp\left(-\frac{d_{ij}^2}{b^2}\right) \quad (2.2)$$

而后者结合距离阈值与平滑衰减，对超出带宽的样本赋予零权重，避免长尾效应。

带宽优化通过交叉验证（CV）或 AICc 准则实现，平衡参数估计的偏差与方差。实证研究表明，GWR 在住宅价格、交通流量等空间建模中表现出优越的适应性。

在评价 GWR 模型时，均方误差 MSE 用于衡量模型在局部区域的预测精度，公式如下：

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (2.3)$$

MSE 的值越小，表示模型拟合效果越好。

决定系数 R^2 反映了回归模型对因变量变异的解释能力，取值范围为 0 到 1，值越大表示模型拟合越好，公式如下：

$$R^2 = 1 - \frac{1}{n \times \text{SST} \times \text{MSE}} \quad (2.4)$$

其中，SST 为总平方和。但是由于未考虑自变量数量对解释力的影响，可能因变量增加而虚高，因此需要引入变量数 k 和样本量 n 的惩罚项以调整 R^2 （Adjusted R^2 ），其公式为：

$$\text{Adjusted } R^2 = 1 - \frac{(1 - R^2)(n - 1)}{n - k - 1} \quad (2.5)$$

以此避免因增加无关变量导致的过拟合。

校正赤池信息准则 AICc 同样用于模型选择，平衡模型拟合优度与复杂度，以避免过拟合。其公式为：

$$AICc = AIC + \frac{2k(k+1)}{n-k-1} \quad (2.6)$$

$$AIC = 2k - 2\ln(L) \quad (2.7)$$

其中，k 为参数数量，L 为似然函数，n 为样本量。

2.2.2 逻辑回归

逻辑回归（LR, Logistic Regression）是一种经典的统计学习方法，尽管其名称中包含“回归”，但它主要用于解决分类问题，通过预测事件发生的概率实现分类^[26]。它通过预测事件发生的概率实现分类。其核心思想是利用线性组合的自变量与逻辑函数（Sigmoid 函数）结合，将线性回归的输出映射到 0,1 区间，表示样本属于某一类别的概率。逻辑回归的模型公式为：

$$P(Y=1|x) = \frac{1}{1 + e^{-(\beta_0 + \sum_{i=1}^n \beta_i x_i)}} \quad (2.8)$$

其中， β_0 为截距项， β_i 为回归系数。

逻辑回归的优势在于模型简单、计算高效，且输出结果具有概率解释性。然而，其假设特征与目标变量间存在线性关系，对非线性问题需引入多项式特征或结合核方法扩展。实际应用中，逻辑回归广泛用于医学诊断等领域^[27]。

2.2.3 决策树

决策树是一种基于树形结构的分类模型，通过递归划分数据实现知识归纳，具体流程图如图 2.2 所示。




图 2.2 决策树算法流程图

其核心思想源于信息论中的熵与信息增益概念，由 J.R. Quinlan 在 ID3 算法中系统化提出^[28]。

每个内部节点代表对某一属性的测试，分支对应属性取值，叶节点则标识最终类别。ID3 算法通过最大化信息增益选择分裂属性，即优先选取能最大程度降低数据不确定性的特征。数据集 D 在特征 A 上的信息熵计算公式如下：

$$\text{Gain}(D, A) = \text{Entropy}(D) - \sum_{v=1}^V \frac{|D_v|}{|D|} \text{Entropy}(D_v) \quad (2.9)$$

$$\text{Entropy}(D) = - \sum_{k=1}^K p_k \log_2 p_k \quad (2.10)$$

其中， V 为特征 A 的取值个数， D_v 为数据集 D 基于特征 A 划分的子集， K 为数据集 D 中的类别个数， p_k 为第 k 类样本的占比。

该方法通过窗口迭代策略处理大规模数据集，仅需部分样本即可生成初步树结构，逐步修正错误分类样本以提高效率。实验表明，ID3 在数万样本、数十属性的场景下仍能高效生成准确模型。为应对现实数据中的噪声与缺失值，改进算法引入统计检验（如卡方检验）过滤无关属性，并通过概率分布处理缺失值，避免过拟合。决策树技术因其直观性、高效性及对噪声的容忍度，成为知识获取与专家系统构建的重要工具，推动机器学习从实验室向工业场景的转化。

2.2.4 随机森林

随机森林（RF，Random Forest）是一种基于集成学习的机器学习算法，由 Breiman 于 2001 年首次提出^[29]，其算法流程图如图 2.3。




图 2.3 随机森林算法流程图

其核心思想是通过构建多棵决策树并结合“Bagging”策略（Bootstrap Aggregating）与特征随机性，提升模型的泛化能力和鲁棒性。在分类任务中，通过组合多棵决策树的预测结果实现最终分类：

$$\hat{y} = \text{mode}\{T_1(x), T_2(x), \dots, T_M(x)\} \quad (2.11)$$

其中, $T_j(x)$ 表示第 j 棵决策树对样本 x 的分类结果, **mode** 函数选取众数作为最终类别。

2.2.5 XGBoost

XGBoost (XGB, eXtreme Gradient Boosting) 是一种高效可扩展的基于梯度提升树的集成机器学习算法, 其核心通过集成多棵回归树实现预测, 采用加法训练策略逐棵优化模型^[30], 算法流程图如图 2.4 所示。




图 2.4 XGBoost 算法流程图

相较于传统梯度提升树, 其创新主要体现在三个方面:

第一, 引入正则化目标函数:

$$Obj^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t)}) + \sum_{k=1}^t \Omega(f_k) \quad (2.12)$$

$$\Omega(f_t) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 \quad (2.13)$$

通过叶节点数 T 和权重 w 的 L_2 正则项控制模型复杂度;

第二, 提出加权分位数草图算法, 将二阶梯度统计量 h_i 作为样本权重, 实现高效的特征分位数近似计算;

第三, 设计了稀疏感知分割策略, 通过默认方向处理缺失值与稀疏特征, 使计算复杂度与有效特征数线性相关。

系统层面, XGBoost 采用列块存储结构优化特征排序与统计聚合, 结合缓存感知访问与核外计算技术, 支持十亿级数据的高效处理。其模型由 k 个基模型组成, 第 t 次迭代后样本 i 的预测公式如下:

$$\hat{y}_i^{(t)} = \sum_{k=1}^t f_k(x_i) = \hat{y}_i^{(t-1)} + f_t(x_i) \quad (2.14)$$

2.3 分类问题在机器学习中的评价指标

准确率（Accuracy）反映了模型对所有样本的整体预测正确率，其公式为：

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{FP} + \text{FN} + \text{TN}} \quad (2.15)$$

其中，TP（True Positive，真正例）为模型正确预测为正类的样本数，TN（True Negative，真负例）为模型正确预测为负类的样本数，FP（False Positive，假正例）为模型错误预测为正类的负类样本数，FN（False Negative，假负例）为模型错误预测为负类的正类样本数。

精确率（P，Precision）反映了模型对正类判别的准确性，体现的是预测结果的可靠性。其公式为：

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (2.16)$$

召回率（R，Recall）也称真正率 TPR，定义为正样本中被正确预测的比例，反映了模型对正样本的覆盖能力。其公式为：

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (2.17)$$

F1 分数（F1-Score）定义为精确率与召回率的调和平均数，其公式为：

$$\text{F1} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (2.18)$$

F1 分数用于评估精确率与召回率之间的平衡性。在分类类别分布不均时，F1 分数比准确率更具参考价值。它对极端值敏感，若精确率或召回率接近 0，F1 分数会显著下降，迫使模型需同时优化两者。

受试者工作特征曲线（ROC，Receiver Operating Characteristic Curve）表征假正率 FPR（False Positive Rate）与真正率 TPR（True Positive Rate），即召回率 R 的关系。假正率的公式为：

$$\text{FPR} = \frac{\text{FP}}{\text{FP} + \text{TN}} \quad (2.19)$$

ROC 曲线通过调整分类阈值生成，对样本分布不敏感，非常适用于正负样本比例接近的场景。如果一个模型的 ROC 曲线完全位于另一个模型的 ROC 曲线之上，则前者的性能优于后者。ROC 曲线下的积分面积称作曲线下面积（AUC，Area Under the Curve），其公式为：

$$\text{AUC} = \int_0^1 \text{TPR} d\text{FPR} \quad (2.20)$$

AUC 取值范围在 0 到 1 之间，可以反映模型整体区分能力。AUC 值越大，模型的性能越好。AUC 接近于 1 表示模型的判别能力良好。

精确率-召回率曲线（PR，Precision-Recall Curve）表征精确率 P 与召回率 R 的关系，反映了不同阈值下的性能权衡。曲线越靠近右上角，模型性能越好。PR 曲线下的面积可以用于综合衡量模型在不同召回率水平下的精度表现。

2.4 克里金插值

克里金插值（Kriging interpolation）在本研究中用于根据道路随机采样点的数据预测未采样路段与城市空间的连续空间分布。它是一种基于空间自相关性的最优无偏估计方法，其核心思想是通过半变异函数量化空间数据的结构特征，并利用已知采样点的加权线性组合预测未知点的属性值。其数学模型可表示为：

$$Z^*(x_0) = \sum_{i=1}^n \lambda_i Z(x_i) \quad (2.21)$$

其中， $Z^*(x_0)$ 为待插值点的估计值， $Z(x_i)$ 为已知点属性值， λ_i 为权重系数，可通过求解克里金方程组确定：

$$\begin{cases} \sum_{j=1}^n \lambda_j \gamma(x_i, x_j) + \mu = \gamma(x_i, x_0) \\ \sum_{j=1}^n \lambda_j = 1 \end{cases} \quad (2.22)$$

其中， μ 为拉格朗日乘子， $\gamma(x_i, x_j)$ 为半变异函数，表征空间自相关性。

本研究选取普通克里金法（OK, Ordinary Kriging）作为空间插值方法。尽管克里金法存在多种理论扩展形式，包括泛克里金（Universal Kriging）、协同克里金（Co-Kriging）等变体，但基于区域化变量满足二阶平稳假设的普通克里金方法，在保证估计量无偏性和最优性的前提下，其算法实现具有显著的稳定性优势。尤其针对样本空间分布稀疏的实验条件，该方法通过半变异函数建立的空间自相关模型能够有效降低估计方差，同时保持计算效率。相较而言，其他克里金变体或需额外参数估计，或受限于协变量数据的可获得性，因此本研究将研究范围限定于普通克里金法，其扩展形式的应用将留待后续研究探讨。

3 多维交通事故数据与街景图像的融合与预处理

3.1 数据来源与相关说明

本研究在算法模型训练与对比分析过程中，采用美国全国交通事故数据集（A Countrywide Traffic Accident Dataset）^{[31][32]}作为基础数据来源。该数据集完整收录了 2016 年至 2022 年期间全美范围内经官方记录的交通事故数据，累计样本量达 7,284,561 条，具有较高的时空覆盖度和样本代表性。原始数据包含事故时间、地理坐标、天气状况、道路类型等 33 个维度的结构化信息，为多维数据交通事故分析提供了丰富的特征维度。

鉴于谷歌街景图 API 调用频率限制及历史图像获取的技术约束，本研究通过空间抽样方法对原始数据集进行分层筛选。具体而言，首先基于事故地理坐标建立空间索引，结合 GIS 技术划定加利福尼亚州北部（36°N—40°N，124°W—120°W）作为核心研究区域，该区域覆盖旧金山湾区等交通事故高发地带，具有典型的地形特征和交通流量特征。随后运用随机分层抽样方法，按照事故严重程度进行等比例抽样，最终获得 21,716 条有效样本数据。

如图 3.1 所示，经过筛选的样本数据在事故严重程度分布上呈现良好的均衡性：I 级事故占比 23.1%，II 级占 35.6%，III 级占 23.1%，IV 级占 18.2%。这种均衡分布有效避免了类别不平衡对机器学习模型训练造成的潜在偏差，同时确保了模型在不同事故等级上的泛化能力。




图 3.1 加利福尼亚州北部交通事故地理位置与严重程度分布图

该数据涵盖事发时间、详细事发地信息、严重程度、事发时气象条件、事故描述等众多字段，

且其中部分数据有缺失，因此仅摘取其中与本研究相关且数据完整的字段，在表 3.1 中列出：

表 3.1 原始数据集字段与本研究选用字段（用红色标出）

字段名称	字段描述	字段名称	字段描述	字段名称	字段描述
ID	编号	Street	街道	Humidity(%)	湿度
Source	数据源	City	城市	Pressure(in)	气压
Severity	严重程度	County	县	Visibility(mi)	能见度
Start_Time	起始时间	State	州	Wind_Direction	风向
End_Time	结束时间	Zipcode	邮编	Wind_Speed(mph)	风速
Start_Lat	起始纬度	Country	国家	Precipitation(in)	降水
Start_Lng	起始经度	Timezone	时区	Weather_Condition	天气
End_Lat	结束纬度	Airport_Code	机场代码	Sunrise_Sunset	昼夜
End_Lng	结束经度	Weather_Timestamp	天气时间戳	Civil_Twilight	民用暮光
Distance(mi)	发生距离	Temperature(F)	气温	Nautical_Twilight	航海暮光
Description	描述	Wind_Chill(F)	风温	Astronomical_Twilight	天文暮光

其中，环境特征中的气象数据具体采集自事故地点最近机场气象站记录的航空例行天气报告（METAR）实时报文。针对原始气象数据包含的所有观测字段，本研究基于特征工程策略实施结构化筛选：优先保留温度、湿度、能见度、风速、气压五个连续型特征，剔除 Weather（天气现象）和 Wind_Direction（风向）等非结构化描述字段，此举主要基于两点考虑：（1）定性描述字段存在语义界定不清晰以及观测标准不统一的问题；（2）分类变量在跨区域数据整合过程中易出现编码不一致的问题，影响其在机器学习模型中的有效数值表示与泛化能力。

在事故严重程度分级方面，原始数据集虽包含事故描述，但缺乏标准化分级体系。为此，本研究依据美国交通运输部《事故创伤分类量表》^[33]建立分级映射机制，参照 NHTSA 推荐的 KABCO 量表损伤程度分级标准，将创伤等级映射为四级事故严重程度指标，详细对应关系见表 3.2 所示。

表 3.2 事故严重程度与加利福尼亚州创伤等级的映射关系

严重程度	创伤代号	详细定义
IV	致命创伤	在事故中直接死亡，或在事故后 30 天内因该创伤导致死亡的情况
III	严重创伤	除致命创伤外的骨折、关节脱位或肢体变形、严重撕裂伤，或处于昏迷状态
II	其他可见创伤	淤青；身体受外力击打（例如眼部淤青、鼻出血）；擦伤
I	疼痛报告	包括真实的内伤或其他不可见损伤，也可能包含虚假的报告

3.2 街景图像

本研究的重点之一在于采集道路环境与设施数据，因此需要先获取每个采样点的街景图像，然后在数据标注前确定语义标签种类，完成语义模型训练后对所有街景图像进行分割提取，为量

化道路环境要素的空间分布特征，使用各语义标签的面积占比作为表征性指标。具体处理街景图的技术路线如图 3.2 所示。




图 3.2 街景图像处理流程图

3.2.1 街景图像获取

本研究采用多视角街景图像采集策略，调用谷歌地图的街景图接口（SVI, Google Street View Imagery API）获取街景图像数据。为模拟驾驶员视角，每个观测点抓取与行驶方向呈 0°、90°、180°和 270°的最多四张街景图像（部分点位可能因数据缺失不足四个方向），形成 360°空间覆盖。原始图像分辨率统一调整为 640×640 像素，采用 PNG 格式存储。为确保数据的准确性，街景图的时段多为日间，天气能见度条件良好。

3.2.2 语义分割建模

本研究基于 YOLOv11 架构构建语义分割网络，在原生目标检测框架基础上扩展像素级分类能力。

在建模前采用双重数据隔离机制构建标注数据集，以规避模型过拟合风险。从原始交通事故数据集中独立抽取容量为 500 的标注子集，并按 7:2:1 的比例划分为训练集(train)、验证集(validate)和测试集(test)，严格排除先前节选的 21716 条数据。该策略确保标注样本在空间分布与时间跨度等维度与预测集保持独立同分布特性。

同时，基于任务需求建立互斥且完备的语义类别集合。本研究构建面向道路安全评价的多维度语义标签体系，基于城市交通工程学原理，将街景要素划分为 9 个互斥的语义类别，如表 3.3

所示。每个类别的定义遵循《ISO 39001 道路交通安全管理体系标准》。

表 3.3 语义标签体系与安全指标映射表

语义类别	语义对象
高架设施	立体交通枢纽与跨线桥梁结构体
隔离设施	中央分隔带、机非隔离栏等硬质分隔物
路面	路面
地面标线	车道线、转向箭头等热熔标线
交通标志	禁令、警告、指示类反光标识牌
路灯	道路照明设施及其支撑结构
信号灯	通过三色灯光实现交通流时空分割的设施
人行道	铺装人行道及附属无障碍设施
绿化植被	行道树、中央绿带等植物群落
天空	无遮挡的天际线区域

数据标注的格式统一采用 YOLO Segmentation 格式，每张图像对应一个同名的 TXT 格式文件，遵循“<class_id> <xi> <yi>”的格式，其中 class_id 为语义标签的类别，xi 与 yi 为归一化的多边形顶点坐标，即相对于图像宽度和高度的比例。本研究先使用 LabelMe 生成 JSON 格式的标注文件，再通过 Python 脚本转换为规定的输入格式。

将标注完毕的图像投入 YOLO 预加载模型进行训练。在本研究中，YOLOv11n-seg 模型的参数配置基于算法性能优化与计算资源平衡的双重考量。模型架构选择 YOLOv11n-seg.yaml 官方配置文件，其轻量级设计适用于街道图像分割任务对实时性的需求，同时继承 YOLO 系列在目标检测与分割任务中的结构优势。经过多轮训练比较后，超参数选择如表 3.4 所示。

表 3.4 YOLO 语义分割模型的超参数选择

超参数	含义	取值	超参数	含义	取值
task	任务类别	segment	epochs	训练轮数	2000
optimizer	优化器类型	auto	warmup_epochs	学习率预热轮数	5.0
batch	每批次样本数量	16	patience	早停容忍轮数	100
save	模型保存策略	true	imgsz	图片尺寸	640
cache	数据集缓存策略	false	lr0	初始学习率	0.0001
workers	数据加载线程数	8	lrf	最终学习率系数	0.0001
augment	数据增强	True			

训练轮数设置为 2000 epoch 以充分挖掘模型潜力，配合 100 patience 的早停机制动态终止训练，既防止过拟合又避免无效计算。输入图像已预先缩放至 640×640 像素，在保留细节信息与

降低计算复杂度之间取得平衡，该尺寸已被证实为 YOLO 系列模型的最佳实践尺寸之一。批处理量设置为 16 以适配单块显卡的显存容量，8 个工作进程并行加载数据以提升数据管道效率。学习率采用恒定策略，配合 5 个 epoch 的线性预热阶段，确保训练初期参数更新的稳定性。数据增强功能激活了包括几何变换与色彩空间扰动在内的实时增强策略，有效提升模型对街道场景光照变化和视角差异的鲁棒性。禁用内存缓存以避免大规模街景数据集对系统内存的过度占用。

最终，如图 3.3 所示，训练完毕的模型在测试集上的性能通过精度-召回率（PR）曲线得到系统评估，整体平均精度均值（mAP@0.5）达到 0.646，表明模型对街道场景的语义分割具备中等泛化能力。各类别性能呈现显著分化：高频且结构稳定的“天空”（AP=0.925）和“信号灯”（AP=0.888）表现最优，其高精度源于目标形态的规则性与场景中的显著空间位置特征；而“交通标志”（AP=0.309）和“路灯”（AP=0.472）等小尺度或易遮挡目标的检测能力较弱，可能与训练数据中该类别的样本数量不足及复杂光照干扰有关。中等规模目标如“地面标线”（AP=0.704）与“人行道”（AP=0.602）的分割精度验证了模型对连续几何结构的捕捉能力，但“隔离设施”（AP=0.554）的较低性能暗示道路边缘特征的提取仍存在优化空间。另外，“绿化植被”类别（AP=0.682）精度曲线陡降反映出模型对不规则自然形态的表现为不同的敏感度。PR 曲线的整体形态显示，当召回率超过 0.6 时，多数类别精度急剧衰减，表明模型在高召回需求场景下存在误检率上升的瓶颈。后续研究可针对性增强小目标特征提取模块，并通过困难样本挖掘策略提升低 AP 类别的判别性特征学习。




图 3.3 YOLO 语义分割模型在测试集上的 PR 曲线图

如图 3.2 的第二阶段所示，在完成 YOLO 语义分割模型训练后，采用自动化处理架构对数据集所有观测点的街景图执行多目标语义分割，每个观测点对应数张不同朝向的图像。这些图像记录并标出了不同语义标签的分割区域以及对应的像素面积，供后续进行归一化与一致性处理。

3.2.3 预测后处理

如图 3.2 的第三阶段所示，得到每个观测点的分割预测图像后，建立自动化后处理流水线（Post Processing），主要包含以下关键步骤：

（1）利用 OpenCV 图像处理库解析模型输出的分割掩膜，按语义标签类别计算各街景图像的像素面积占比。语义标签类别 c 的占比

$$P_c = \frac{N_c}{W \times H} \quad (3.1)$$

其中， N_c 为对应类别的像素数量， W 为原图宽， H 为原图高。

（2）对同一观测点的多方向预测结果取各方向占比的算术平均值作为该点的最终表征值：

$$\bar{P}_c = \frac{1}{n} \sum_{i=1}^n P_{c,i} \quad (3.2)$$

其中， n 代表该观测点有效的街景图像数量，取值为 $1 \leq n \leq 4$ 。

3.3 多维数据融合与特征工程

3.3.1 数据集成与特征体系构建

在获取了各采样点的街景图像表征值后，结合原始事故数据的气象与位置字段，构建包含 4 个大类、17 个特征变量的解释体系，如表 3.5 所示：

表 3.5 变量体系

变量类型	代号	变量名称	量纲
目标变量	SVT	事故严重程度	顺序尺度
位置特征变量	LAT	纬度	°
	LON	经度	°
	TMP	温度	°F
气象特征变量	HUM	湿度	%
	PRS	气压	inHg
	VIS	能见度	mi
	WSP	风速	mph
街景特征变量	ROF	街景图中高架设施面积占比	1
	SEP	街景图中隔离设施面积占比	1
	GRN	街景图中绿化植被面积占比	1
	SUR	街景图中路面面积占比	1
	MRK	街景图中地面标线面积占比	1
	SKY	街景图中天空面积占比	1
	LMP	街景图中路灯面积占比	1
	TRF	街景图中信号灯面积占比	1
	SGN	街景图中交通标志面积占比	1
	PAV	街景图中人行道面积占比	1

3.3.2 变量相关性分析

相关系数矩阵的构建基于变量两两之间的相关系数（ r ，Correlation Coefficient）计算，其核心公式为皮尔逊（Pearson）相关系数。具体计算过程如下：

$$r = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum (X_i - \bar{X})^2 \cdot \sum (Y_i - \bar{Y})^2}} \quad (3.3)$$

其中， X_i 和 Y_i 为两个变量的观测值， $\bar{X}$ 和 $\bar{Y}$ 分别为其均值。该公式量化了变量间的线性关系强度，取值范围为 $[-1, 1]$ ，1 表示完全正相关，-1 表示完全负相关，0 表示无线性关联。

除了使用 r 描述性统计变量相关性的强弱，还需验证相关性是否具有统计学意义，因此需要计算 p 值（ p ， p -value）。 p 值定义为在原假设成立的前提下，观测到当前数据（或更极端数据）出现的概率，计算过程如下：

（1）设定假设检验。设原假设 H_0 为两个变量之间无线性相关（总体相关系数 $\rho = 0$ ），备择假设 H_1 为两个变量之间存在线性相关（ $\rho \neq 0$ ）。

（2）计算检验统计量。皮尔逊相关系数的 p 值通过 t 检验计算：

$$t = r \sqrt{\frac{n-2}{1-r^2}} \quad (3.4)$$

其中， r 为皮尔逊相关系数， n 为样本量。

（3）确定自由度：

$$df = n - 2 \quad (3.5)$$

（4）根据 t 统计量，使用 t 分布计算双侧 p 值：

$$p = 2 \times P(T \geq |t|) \quad (3.6)$$

其中， T 服从自由度为 df 的 t 分布。该公式量化了数据与原假设间矛盾程度的概率。 p 值越小，数据与原假设的矛盾越强。

在确定了模型输入的特征变量后，构建如图 3.4 所示的变量相关系数矩阵。下三角矩阵的值代表对应横轴与纵轴自变量之间的相关系数，星号代表了 p 值的大小。上三角矩阵对该系数进行了直观的可视化，通过彩色实心圆（正相关为红色，负相关为蓝色）直观展示相关性强度。两个特征变量越相关，对应的圆半径越大，颜色越深。由于变量自身的自相关系数全部为 1，本图中对角线元素表征为各特征变量与目标变量（即事故严重程度）之间的相关性系数，同时通过直接填充颜色深浅以直观表现。




图 3.4 变量相关性系数矩阵热力图

在 9 个街景特征中，天空区域（SKY）与高架设施（ROF）的相关系数达 -0.65 ，其负向关联的可能原因在于，高架设施在街景图像中的垂直投影方位会显著压缩天空可视区域的空间占比，这种几何遮挡在道路基础设施密集区域尤为突出。路灯（LMP）与信号灯（TRF）呈现中等程度的正向关联（ $r = 0.37$ ），反映出城市道路照明系统与交通管制设施在空间布局上的相似特征。这两组关键相关性在热力图中通过色阶跨度较大的热力单元得以直观表征。其余变量间的相关系数绝对值均低于 0.3，表明多数自变量间不存在显著共线性问题。

对于各特征变量与目标变量的相关性（对角线元素），在显著性较高（ $p < 0.05$ ）的因素中，气压、路灯和信号灯有相对较大的相关系数（ $r = -0.10$ ），但是总体数值上较小，证明它们与事故严重程度有微弱的负相关。其余特征的相关系数都极小，表明各特征自变量与目标变量间同样不存在显著关联。

这种相对独立的数据特征不仅有利于提升机器学习模型训练过程的数值稳定性，更为特征重要性分析提供了可靠的解释性基础。

4 基于机器学习的交通安全因子与事故严重程度关系建模

4.1 模型的训练与预测

鉴于事故严重程度变量具有有序次型测量尺度特征，本研究依据有序响应变量建模原则，在机器学习框架中将其作为四分类序次预测任务进行处理。

4.1.1 地理加权回归

由于输入特征包含地理位置信息，因此考虑使用地理加权回归对数值进行建模。在本研究中的四分类任务中应用地理加权回归时，需将离散型分类问题转化为连续型回归框架进行建模。由于目标变量事故严重程度存在自然顺序，因此直接按照 I-IV 的对应关系对其赋予 1-4 的数值。

在构建地理加权回归模型时，通过 `Sel_BW` 对象的黄金分割搜索法自动优化，以空间坐标数据为基础自适应调整核函数半径，以捕捉交通事故严重程度与道路特征之间的空间异质性。特征矩阵与目标变量均经过 `Z-Score` 标准化处理，消除量纲差异对空间权重计算的干扰。模型采用默认双平方空间核函数，显式表达相邻地理单元对回归系数的衰减效应，其带宽阈值通过留一交叉验证确定，确保局部回归模型在空间非平稳性下的统计稳健性。

在验证地理加权回归对空间异质性的捕捉能力时，本研究引入全局回归模型（GR，Global Regression）作为基准参照。对比两类模型的统计指标如表 4.1 所示，GWR 的调整后 R^2 较 GR 提升 743.59%，表明引入空间异质性后模型解释力显著提升，也证明局部模型对空间异质数据的适配优势。GWR 的 $AICc=56557.389$ ，远低于 4224.5，说明 GWR 模型对数据的拟合更优。GWR 的 $RSS=12607.856$ ，较全局模型减少 39.5%，同样验证了局部模型的拟合优势。

表 4.1 GR 与 GWR 模型训练结果

模型	R^2	Adjusted R^2	$AICc$	MSE
GR	0.04	0.039	60781.913	0.96
GWR	0.42	0.329	56557.389	0.58
提升效果	950.00%	743.59%	7.47%	65.52%

尽管 GWR 捕捉到了数据的空间异质性，但是使用测试集在 GWR 上进行测试时，准确率仅有 44.78%，原因分析如下：

（1）将离散型四分类变量强制编码为连续数值导致预测值难以精准映射回原始类别，特别是事故严重程度间的非线性跃迁关系被线性假设破坏；

（2）由于道路特征变量在空间邻域内可能存在较强的多重共线性，导致部分局部回归点的系数矩阵条件数超过 30，从而影响 GWR 模型中参数估计的数值稳定性与结果的可靠性。

由此可见，GWR 虽然在精确量化空间参数变化的研究中仍不可替代，但分类任务中应慎用回归框架。

4.1.2 逻辑回归

逻辑回归模型中，最大迭代次数设置为 1000，为模型提供了充足的优化时间，确保在高维交通数据下损失函数能够收敛至稳定状态。正则化参数设为 L2，通过默认的 $C=1.0$ 隐式控制模型复杂度，平衡系数权重以防止特征过拟合。随机种子的固定保证了实验可复现性，使得不同交通数据划分下的模型表现可比。这一配置使逻辑回归在保持高解释性的同时，通过线性边界有效区分事故严重程度概率分布，适用于初步特征重要性分析。

4.1.3 随机森林

在随机森林模型中，树数量设为 100，通过多棵弱相关决策树的投票机制降低方差，确保模型对复杂模式的稳定捕捉；树深度控制不限制深度（None），允许单棵树充分学习数据内在结构，适用于中小规模数据集的特征交互挖掘；节点分裂条件中，内部节点划分最小样本数默认为 2，叶节点最小样本数设为 1，赋予模型对稀疏事故样本的高灵敏度；特征随机性默认采用 auto 模式，即 $\sqrt{p}$ 特征数，通过约束每棵树的特征空间多样性，避免特征变量多重共线性导致的决策路径趋同；抽样机制启用有放回抽样，配合袋外样本误差评估，为数据分布偏移提供无偏性能估计。该配置使随机森林在保持非线性决策优势的同时，通过特征重要性排序揭示气象特征、街景特征等变量对事故风险的贡献度，尤其适用于多维交通数据的交互效应解析。

4.1.4 决策树

决策树模型中，未显式限制树的最大深度，允许模型自主划分节点至纯叶子状态，从而完整学习交通数据中的细节规则（如特定时段与事故类型的强关联）。然而，随机种子的固定避免了因特征分裂顺序随机性导致的模型波动。将内部节点分裂所需的最小样本数设置为 2，叶子节点的最小样本数设置为 1，符合交通事故数据非均衡性的特点。可能在小规模数据中捕捉局部模式，但也有过拟合的风险。对于本研究探索交通事故数据中的关键决策路径而言很有帮助。

4.1.5 XGBoost

在构建 XGBoost 分类器时，本研究通过贝叶斯优化（Bayesian Optimization）与随机网格搜索（Randomized Grid Search）的对比调参实验，系统性探索超参数组合对交通事故预测性能的影响。其得到的最优模型如表 4.2 所示。

表 4.2 XGBoost 调参比较结果

调参方式	Precision	Recall	F1-Score	Accuracy
贝叶斯优化	0.83	0.81	0.81	0.8382
随机网格搜索	0.83	0.81	0.81	0.8375

贝叶斯优化基于高斯过程代理模型，以迭代方式聚焦高潜力参数空间区域，相较于随机搜索的均匀采样策略，其以更少的计算代价（减少约 60% 的候选组合评估次数）锁定最优参数：树的数量 500 和学习率 0.1 的协同配置，通过大规模弱分类器集成与低步长衰减策略，有效抑制梯度

提升过程中的过拟合风险；树的最大深度 10 在贝叶斯搜索中被验证为平衡模型容量与泛化的临界点，既能解析交通数据中高维非线性关联，又避免因过深分裂导致的规则碎片化。此外，贝叶斯优化精准识别出极小的最小叶子节点权重 0.0077，该阈值通过统计显著性检验，允许模型在稀疏特征（如特殊天气下的罕见事故模式）中捕捉微弱信号，同时借助特征采样比例 0.5 约束单棵树的信息视野，强制模型分散学习不同特征子集的判别模式，增强集成多样性。虽然贝叶斯优化相较于随机网格搜索的测试集准确率仅提升约 0.08%，但仍然验证了贝叶斯优化在交通事故复杂特征空间中的全局寻优能力，使模型精准达到了泛化性能的峰值。

4.2 模型性能比较

在各模型训练完毕后，为选出最佳的模型，系统评估了地理加权回归（GWR）、XGBoost（XGB）、逻辑回归（LR）、决策树（DT）和随机森林（RF）五类模型在四级事故严重程度（I-IV 级）分类任务中的性能表现。由于 GWR 的准确率（44.78%）远低于机器学习模型，在后续比较中仅对比机器学习模型的结果。

如表 4.3 所示，各模型的精确率与回归率由所有目标类别的算术平均值得到。从精确率来看，各个模型中，XGBoost 模型的精确率最高，为 0.83，其次是随机森林模型，为 0.76，决策树模型相对较低，为 0.66；逻辑回归模型最低，仅 0.43。从召回率来看，各个模型中，XGBoost 模型的召回率最高，为 0.81，其次是随机森林模型，为 0.73，决策树模型和逻辑回归模型的召回率则为 0.66 和 0.37，表现欠佳。从 F1 值来看，各个模型中，XGBoost 模型的 F1 值为 0.81 最高。总体而言，XGBoost 模型的性能要显著优于其他模型。

表 4.3 机器学习模型比较结果

模型	Precision	Recall	F1-Score
XGB	0.83	0.81	0.81
LR	0.43	0.37	0.34
DT	0.76	0.73	0.73
RF	0.66	0.66	0.66

为了更直观地辨别模型的性能，模型的混淆矩阵热力图如图所示，横轴表示模型预测类别（Predicted），纵轴对应真实类别（Actual），每个单元格的色阶深度与其样本数量正相关，对角线元素的深色分布表明其整体预测有效性。对比四模型可见，XGBoost 模型在四类样本识别上均展现出最优性能。




图 4.1 XGBoost、逻辑回归、决策树与随机森林模型的混淆矩阵对比图

为了更精确地评估各模型的性能，本研究还采用了 ROC 曲线和 PR 曲线分析，同时选取性能最优的模型进行解释性分析，以评估模型的泛化能力。

如图 4.2 所示，在绘制 ROC 曲线时，本研究将四分类任务转化为对每个分类（即严重程度）的独立二分类任务，以计算它们的 TPR 与 FPR。为使结果图形更加直观，分别绘制四个模型的 FPR-TPR 分布曲线，并通过核密度估计生成概率分布，如图中的浅色区域。最后采用宏观平均法计算各模型整体性能指标，据此绘制各模型的 ROC 代表线。




图 4.2 XGBoost、逻辑回归、决策树与随机森林模型的 ROC 曲线对比图

图中，XGBoost 模型展现出最优分类性能（AUC=0.96），其代表线紧贴左上角，显著优于逻辑回归模型。而随机森林与决策树的 AUC 分别为 0.92 和 0.78，呈现中等判别效能。在交通事故预测中，较高的 AUC 表明模型能够有效区分不同严重程度的事故。从实际交通场景来看，该模型能够根据多种输入特征，准确预估事故发生的严重程度，为交通管理部门提供及时有效的决

策支持。

如图 4.3 所示，与 ROC 曲线的绘制相似地，分别绘制了四个模型的 P-R 分布曲线，并通过核密度估计生成了概率分布区域，最后宏观平均得到每个模型的代表线。




图 4.3 XGBoost、逻辑回归、决策树与随机森林模型的 PR 曲线对比图

图中，XGBoost 模型的代表线贴近右上角，同样表现最优。虽然随机森林的部分类别也有良好的效果，但是稳定性上仍不如 XGBoost。较高的准确率表示模型预测的某一严重程度的事故实际发生的概率较高；较高的召回率表示模型对该实际严重程度的事故有较大比例的准确预测。XGBoost 模型的表现不仅能够准确识别真正的严重事故，还能减少事故被误判为严重事故的情况。这种高精确率的判断机制能够为交通救援资源的配置提供参考，从而提高交通应急管理的效率。

综合以上混淆矩阵、ROC 曲线、PR 曲线，以及具体的精确率和召回率来看，XGBoost 最适合用于本研究事故严重程度预测。

4.3 解释性分析

4.3.1 变量影响模式分析

图 4.4-4.7 展示了基于 XGBoost 的事故严重程度 I 级至 IV 级的个体条件期望 (ICE, Individual Conditional Expectation) 置信区间与部分依赖图，揭示了事故严重程度与多维预测因子间的复杂关系。该系列 ICE-PDP 复合图表通过网格布局系统呈现了 17 个特征对目标变量的非线性作用机制。图中横轴代表被分析特征的变化区间，纵轴对于 PDP 曲线表示模型在对应类别上预测概率的全局平均值，即固定其他特征时，目标变量的预测概率均值；对于 ICE 置信区间表示单个样本在对应类别上的预测概率。红色曲线代表 PDP 均值趋势，揭示了各特征在全局尺度上的平均边际效应，该曲线上升时，特征值增加，模型预测概率同步增加，表明该特征与目标变量呈正相关。浅蓝色阴影代表 ICE 置信区间，体现了样本群的预测结果如何随特征变化而改变，量化了样本异质性，置信区间展宽直接影响了样本群对特征变化的响应差异程度。区间宽度越大，群体分化现象越明显，可解释性就越低，说明特征可能存在显著的异质性或交互作用。




图 4.4 I 级事故基于 XGBoost 模型的个体条件期望置信区间与部分依赖图




图 4.5 II 级事故基于 XGBoost 模型的个体条件期望置信区间与部分依赖图




图 4.6 III 级事故基于 XGBoost 模型的个体条件期望置信区间与部分依赖图




图 4.7 IV 级事故基于 XGBoost 模型的个体条件期望置信区间与部分依赖图

每一张图中，小图从左到右、自上而下的排列顺序是依据 XGBoost 模型的原生属性“特征重要性”（`model.feature_importances_`）得到的，该属性的计算基于树模型的结构特性与分裂增益，通过计算特征每次分裂带来的平均损失函数增益，直接反映特征对模型优化的贡献。对所有事故等级而言，风速（WSP）与位置特征位列重要性前三位，紧随其后便是街景特征隔离设施（SEP）与高架设施（ROF）以及其余中等重要性的街景特征。气象特征湿度（HUM）与能见度（VIS）排位最后。该重要性排名指明了后续进行 PDP 分析的关注重点。

风速作为最高重要性因素，对各类事故等级均展现出最显著的纵向概率分布跨度。ICE 曲线

在纵轴方向的集中分布特征（置信区间宽度 ≤ 0.05 ）表明模型预测对风速变化具有样本一致性响应。值得注意的是，不同风速区间之间的 ICE 曲线呈现显著分异，证实样本在风速维度存在显著异质性。从 PDP 趋势分析，I 级与 IV 级事故的预测概率随风速增加呈现系统性下降，而 II 级与 III 级事故则表现出正相关趋势，体现了风速对于 II、III 级事故的正向干预。

对比其他气象参数，温度（TMP）的 PDP 曲线呈现等级特异性响应：在 I 级事故中呈单调上升，II、III 级事故呈 U 型曲线，IV 级事故则呈持续下降趋势。气温分布特征与“低温-路面摩擦系数下降”的物理机制相吻合。气压（PRS）对 I、II 级事故表现出近似的线性正相关，而对 III、IV 级事故呈现近似二次函数关系，推测可能与轮胎物理性能的温度-压力耦合效应相关。

地理坐标（LON，LAT）的对比分析凸显了空间异质性：I 级与 IV 级事故的经纬度曲线较为平稳，而 II 级与 III 级事故的经纬度呈明显的对称趋势，在高经度低纬度区域，II 级事故的发生率更高。

街景图特征的数量最多，平均重要性高，在各等级事故中都表现出明显的走向趋势。宏观上来看，纵向对比街景特征在四张事故等级大图中的 PDP，可以发现它们的共同规律在于，IV 级事故的预测概率上限皆小于 0.18，该值远小于其余事故等级的预测概率下限，其中 I、III 级事故的预测概率下限在 0.225 上下浮动，而 II 级事故的预测概率下限全部大于 0.3，即 IV 级事故的 PDP 曲线恒低于其余等级。该现象表明，在不考虑其他特征变化的情况下，每个街景特征都更倾向于将事故预测为轻微事故，而非高危事故。换言之，不论面积占比，视野中街景特征的存在本身便对发生高危事故有一定的抑制作用。这一发现与梁龙飞的研究结论相呼应，即优化交通设施能够减少道路交通事故^[34]。

具体到每一个街景特征而言，隔离设施的重要性排序最高，同时各事故等级的 PDP 曲线起伏较大。当隔离设施的街景图面积占比（SEP）从 0 增至 0.02 时，各事故等级曲线均出现显著变化，超过 0.02 后趋于平稳，说明该值可能是该特征的关键阈值。随着 SEP 增加，II 级事故概率显著下降约 12.5%，表明隔离设施的存在能有效降低中等事故风险；III 级事故概率上升约 53%，反映过多的隔离设施可能反而会增加危险事故的风险；I 级事故的整体波动小于 ± 0.005 ，说明该特征对轻微事故的影响不显著；IV 级事故概率由 0.18 降低至 0.16，整体降幅较小，证明隔离设施对制约高危事故的有限作用。IV 级事故概率的降低与 III 级概率的微升可能存在此消彼长关系。从 ICE 置信区间的角度来讲，II、III、IV 级事故的置信宽度较窄，表明所有样本对特征变化的响应高度一致，泛化能力良好。I 级事故的 ICE 置信区间较宽，代表 SEP 对 I 级事故的预测不确定性较大。由此，建议隔离设施的建设应大于街景图面积占比的 0.2，同时应配合其他安全设施防止 III 级事故概率的初期上升。

路灯（LMP）、信号灯（TRF）以及路面标志（SGN）有着相似的 PDP 趋势与 ICE 置信区间形状，它们在功能上的共性都是通过引导驾驶员规范驾驶来保证道路安全性。与隔离设施不同，它们对各级事故的 PDP 曲线并未呈现明显的拐点，证明它们的安全效应呈现连续渐变特征。它们各自的面积占比增加时，I 级事故发生率有轻微上升，II 级事故皆保持高位稳定，III、IV 级事故发生概率呈下降趋势。这说明路灯、信号灯与路面标志可以有效减少高危事故的发生。而 I 级事故发生概率随 LMP、TRF 的上升而升高，这可能与高强度照明引发的驾驶员眩光以及误判车速有关。

相对地，地面标识（MRK）和路面（SUR）的 PDP 曲线同样没有拐点，呈现近乎线性的变化特征，但是趋势上却是大致相反的。随着各自的面积占比增加，地面标识的 PDP 在 I、II、III 级事故中都表现为下降，在 IV 级事故中表现为上升；路面的 PDP 在 I、III 级事故表现为上升，而在 II、IV 级事故中表现为下降。可能的原因在于，路面与地面标识有空间上互斥的关系，地面标识面积的增大意味着路面面积的减少，同时减少了发生轻微事故与中等事故的概率。适当的地面标识通过明确路权分配和驾驶规范，可降低轻微事故（如追尾、刮蹭）的发生概率。但是，Jonathan 等人^[35]的研究表明，当标识密度超过每公里 6-8 处时，驾驶员视觉处理能力达到饱和，导致关键风险信息（如急弯、障碍物）被忽视，反而增加严重事故风险。这种现象在复杂路况处尤为明显。这与本研究 MRK 增加反而会增大 IV 级事故预测概率的现象相吻合。不过总体而言，设置地面标识对于抑制中小事故的正向作用是显而易见的。

最后一组街景特征为环境相关特征，天空（SKY）、绿化植被（GRN）、高架设施（ROF），它们都与驾驶员视野相关。取其中重要性最高，全体重要性排位第五的高架设施为例，其 I 级事故的 PDP 曲线呈先降后升再降的趋势，而 IV 级事故 PDP 曲线与之完全相反，它们的中间段区间较长，ROF 区间大约为（0.05, 0.2）。同时，II 级与 III 级事故的 PDP 曲线负相关的线性变化。ROF 增大时，I 级和 III 级事故风险总体呈增加，II 级与 IV 级事故风险总体呈下降。推测体积较大的高架设施可能会阻碍驾驶员视野，阻挡光线，同时快速驶入驶出高架阴影会使驾驶员的瞳孔来不及适应光线，从而导致事故。因此，高架设施的高度设计可参考 I 级事故预测概率上升阶段的街景图面积占比区间值（0.05, 0.2），不应使高架或其立柱遮挡驾驶员视线。

本研究发现各要素的影响机制存在显著差异，后续研究将结合 SHAP 值进行特征贡献度的量化解析，特别是街景特征的影响模式值得深入探讨。

4.3.2 SHAP 分析

SHAP（SHapley Additive exPlanations）是一种基于博弈论的机器学习模型可解释性框架，旨在为模型预测提供理论严谨、公平且一致的特征贡献量化方法。其核心原理是将每个特征的预测贡献视为合作博弈中的收益分配问题，通过 Shapley 值实现特征重要性的数学建模。

对 XGBoost 模型测试集的 SHAP 分析如图 4.8 所示，每个小图代表一个目标变量的事故严重程度等级类别，纵轴为 17 个特征变量，根据对目标变量的影响程度大小由上而下排序。上横轴为每个数据对该类别的 SHAP 的贡献值，对应蜂窝图。蜂窝图由点积聚而成，颜色代表特征值的大小，点积聚的纵宽度代表在对应 SHAP 值上的点数量。下横轴为各特征在该类别的 SHAP 平均值，对应柱状图表示了各特征对目标变量的影响程度。

基于 SHAP 图的研究发现，各特征变量对事故严重程度的解释机制与 PDP 分析结果具有高度一致性。总体而言，I 级与 II 级事故中，气象特征诸如风速（WSP）、气压（PRS）、湿度（HUM）的平均 SHAP 值较高，对事故预测占主导地位；而 III 级与 IV 级事故中街景图特征的整体 SHAP 贡献均值显著超越了气象特征，湿度与能见度（VIS）对该类事故几乎没有影响，而影响因子较大的街景图特征包括隔离设施（SEP）、人行道（PAV）、信号灯（TRF）以及地面标线（MRK）。这表明在高危事故中，道路环境的人为可控因素较自然气象条件具有更强的可干预性。结合前一节街景图特征在 IV 级事故上表现出普遍较低的 PDP 曲线，共同说明了道路设施对于预防高危事

故的重要作用。这也为道路安全工程提供了关键优化方向，可以通过重点完善道路基础设施，并建立地面标线的动态维护机制，针对性地降低严重事故的发生率。




图 4.8 基于 XGBoost 模型的多类别特征 SHAP 贡献对比分析图

在所有气象特征中，风速（WSP）是影响事故严重程度的最主要因素，在事故等级为 I 时，高风速特征值集中分布于 SHAP 值中轴左侧，代表风速越大，发生 I 级事故的概率越小。这验证了高速行驶的车辆遭遇突发的横风，车辆抓地力减弱，导致方向偏移，货车、客车等重心高车型更易侧翻。其他气象参数如温度（TMP）与气压（PRS）对预测结果的影响就较为有限。温度特征在 I 级事故中呈现低温特征左偏分布，而在 III 级事故中则表现为右偏分布，证明了低温环境可使严重事故概率提升；气压则在四类等级中都有明显的数值分异，红蓝平均居于中线两侧，同样验证了 PDP 分析中轮胎物理性能对事故严重程度的影响。能见度（VIS）在 II、III、IV 级事故中的影响极低，且高能见度对 III、IV 级的贡献值集中在中轴附近，证实其与高危事故的弱相关性。

位置特征也表现出显著的特殊性。经纬度在 I 级和 IV 级事故中呈明显对称，较高的经纬度发生 I 级事故的概率较小，且发生 IV 级事故的概率较大，而较低的经纬度则更有可能发生 III 级事故。对于本研究而言，即加利福尼亚州北部的事故严重程度分布会形成西北-东南方向的脊线，并且向西北方向倾斜，这与加州地形引发的西北-东南向风切变走廊形成空间耦合。该分布模式也呼应了前一节所述的 II 级事故西南集聚区，与其共同构成了多尺度空间风险格局。

在街景特征中，隔离设施对 II、III、IV 级事故严重程度的贡献与它的总体重要性一致。在 II

级事故中，隔离设施的样本点集聚在中轴以左，较小值则在右侧形成长尾；与之相对的，III 级事故的隔离设施的样本点集聚在中轴以右，较小值则在左侧形成长尾，而 IV 级事故的隔离设施样本点集聚在中轴附近，小值和大值各自分布在中轴的右侧与左侧。这表明较高的 SEP 会增加 III 级事故发生概率，而减小 II 级与 IV 级事故的发生概率。这与前一节针对 SEP 的分析结论类似，需要建设其他设施以抑制 SEP 对 III 级事故的正向作用。

在 I、II 级轻微事故中，绿化植被（GRN）与天空（SKY）是贡献最大的街景特征，这与严重事故有显著差异。其中，SKY 对 I 级事故产生了正贡献，而 GRN 则产生了负贡献。反观 IV 级事故，GRN 的 SHAP 均值占据了街景设施的最高值，同时，它的表现与 I 级事故完全相反。换言之，更多的绿化或更少的天空均可能会导致更严重的事故。根据吴浩文的研究，天空开阔度与绿视率对驾驶员整体视觉感受影响较大，绿视率高会给驾驶员造成封闭狭窄的空间感受，从而干扰驾驶员的正常行驶^[36]。因此本研究产生此现象的原因推测为：SKY 足够大意味着道路环境开阔、遮挡物较少，这种视觉条件能显著提升驾驶员的远距离视距和动态目标捕捉能力，使得驾驶员及时发现潜在风险；而绿化植被容易在视野中形成动态盲区，并且复杂的植被纹理会使驾驶员注意力分散，因此在保持空间开阔的同时，应适当控制绿化植被面积，并做好反射眩光控制，最大程度避免影响驾驶员的视野与注意力。

在 III 级事故中，人行道和信号灯的蜂群图展现出相似的分布，较小值集中在中轴附近，较大值向中轴左侧扩散，揭示了较小特征值的边际效应微弱，对 III 级事故无明显贡献，而较大特征值则会降低预测 III 级事故的概率，即人行道与信号灯的增加可以有效控制 III 级事故的发生。另外，地面标线对于 III、IV 级道路的影响同样重要，尤其是 IV 级道路，街景特征重要性仅次于绿化植被。其数据分异也较为明显，体现为与 IV 级事故的正相关，地面标线越多，发生严重事故的可能性越大。这也与前一节 MRK 在 IV 级 PDP 呈上升趋势的现象一致。

5 基于城市基础设施的城市道路设施安全空间分析 ——以旧金山为例

5.1 数据采集与处理

本研究以美国加利福尼亚州的旧金山（San Francisco, California, USA）为研究对象，通过 OpenStreetMap（OSM）平台获取城市路网数据。基于 ArcGIS 的空间分析模块，提取道路线要素，包括高速公路（motorway）、主干道（primary）、次干道（secondary）、三级道路（tertiary）、城市快速路（trunk）及居民区道路（residential）六类核心交通网络。通过地理坐标系统转换（WGS84 至 UTM 投影），确保数据空间一致性。在筛选后的道路线要素上，采用线性参考系沿路径方向以 100 米间隔生成规则采样点，形成覆盖全路网的点数据集。接着，进一步将研究区域划分为 $1\text{km} \times 1\text{km}$ 的规则网格单元，在每个网格内随机选取 10 个代表点，最终构建具有空间均衡性的待检测样本集，如图 5.1 所示。




图 5.1 旧金山城市道路网格划分与随机选点图

在得到采样点样本集后，参考 3.2.1 中提取街景图的方法，对采样点进行四向街景图的语义分割预测。最终参考 3.2.3 计算各语义标签的面积占比并对各方向的街景图像加权融合，从而构建表 3.5 所示的街景特征变量。

由于难以获取研究区域内各样本点的精确气象数据，考虑到旧金山城市规模较小，区域内气象特征变化较小，故气象特征参考旧金山气象数据库的平均数据，选用如表 5.1 所示的代表值。

表 5.1 气象特征的选用代表值

气象特征	代号	选用代表值
温度	TMP	58°F
湿度	HUM	72%
气压	PRS	30.03 inHg
能见度	VIS	10 mi
风速	WSP	8.5 mph

5.2 目标变量预测

本研究基于标准化后的空间变量体系，将经过预处理的地理网格数据输入至第四章所构建的 XGBoost 分类模型中进行事故风险预测。模型输出的预测值表征在指定地理坐标点（经纬度位置）处于平均气象条件时，可能引发交通事故的最大概率严重程度等级。依据训练数据集的分类标准，预测结果保持四分类体系，通过建立有序映射关系（I=1，II=2，III=3，IV=4）将其量化为道路危险系数指标。该指标数值与事故严重程度呈正相关关系，即数值越大表明该空间单元在基准气象条件下发生高严重程度事故的概率越大。图 5.2 展示了基于该模型输出的危险系数分布结果，直观反映了研究区域内交通事故风险的差异化空间格局。




图 5.2 旧金山道路危险系数预测值结果分布

图中，危险系数分布呈现显著的不均衡性，II 级事故占比高达 87.5%，构成空间风险的主体部分，而 IV 级事故仅占 1.2%，甚至没有 I 级事故的出现，显示出典型的“长尾分布”特征。这种偏态分布可能源于空间异质性规律的影响——具备 IV 级严重程度的地理单元（如连续急弯陡坡、混合交通流冲突点等）本身具有稀缺性，其空间分布受地形条件、道路设计规范等刚性约束，在区域路网中仅存在于特定拓扑节点。值得注意的是，I 级占比(0)、III 级占比(11.4%)与 II 级形成数量级差异，暗示着危险系数过渡区域在空间分布上具有明显的阈值效应，这可能与道路安全设施的服务半径、驾驶员行为模式等非线性因素相关。

5.3 安全空间可视化

如图 5.3 所示，本研究通过空间插值技术构建旧金山城市安全风险可视化模型。数据预处理

阶段采用 ArcGIS 平台实施双重空间分析策略：针对道路危险系数，通过普通克里金法对离散点数据进行空间插值，经栅格化处理生成线要素热力图，采用紫色渐变色阶表征危险系数（色阶范围 2.002-3.415），颜色越深，代表路段危险系数越高；针对城市空间危险系数，基于先前划分的 1km×1km 规则网格单元计算内部所有点的算术平均值作为网格代表值，以网格几何中心坐标为空间基准实施二次克里金插值，最终通过面要素核密度估计生成冷暖渐变色阶热力图（色阶范围 0.054-2.063），暖色调代表区域危险系数高。




图 5.3 旧金山城市道路设施安全空间热力图

可视化结果表明：道路与城市空间高危区域呈现显著空间耦合特征。地图东北角的全红色小岛为金银岛（Treasure Island），横跨全美的 80 号国际公路由此沿旧金山-奥克兰海湾大桥（San Francisco-Oakland Bay Bridge）到达旧金山，并以 101 号国道的交会枢纽为终点。80 号公路在旧金山境内的危险系数居高不下，所经之处区域皆表现为红色，海湾大桥全段都为深紫色，道路与空间危险系数皆保持在 2.3 以上。

280 号国际公路作为 80 号公路的辅助线路，以其终点作为起点，同时向南延展了 80 号公路的高风险带。以 280 号公路为旧金山高危风险路段的核心轴线向西南方向延续，危险系数在与 101 号国道交汇处有所下降，并表现出狭窄的鞍部，随后便沿路线继续爬升，在与加州 1 号公路的立交枢纽处形成第二个高危区。

101 号国道则表现为中级事故的轴心线，沿线区域多呈橙黄色，一直延续至地图北侧金门大

桥（Golden Gate Bridge）的入口。其余危险路段还包括西侧靠近太平洋的滨水道路，集中在马球场（Polo field）与旧金山动物园（Zoo）附近；以及地图中心 Mt. Davidson 与双子峰（Twins Peak）的登山路径，它们的空间热力图均表现为橙黄色。

与之相对的，地倾西北的居民区（Sunset District）路网整齐，道路热力图颜色较浅，危险系数较低，道路安全性较高。

由此可见，旧金山道路安全的空间异质性特征显著，危险系数沿交通层级梯度衰减（高速公路>国道>城市主干道>支路网），同时呈现水域过渡带向居住区递减的生态梯度特征，该分布模式与城市空间结构理论中“核心—边缘”风险扩散机制具有一致性。

6 结论与展望

6.1 结论

（1）本研究基于 YOLOv11 架构构建了面向道路安全评价的语义分割模型，确定了街景图道路设施的语义标签。在模型训练阶段，通过平衡算法性能与计算资源，确定 YOLOv11n-seg 轻量级网络作为基础架构，并优化超参数配置，使模型在测试集上的平均精度均值 $mAP@0.5$ 达到 0.646，验证了其对于街景要素的语义分割能力。

（2）本研究通过多维数据融合与对比算法建模，构建了基于城市街景图的道路设施环境安全评价体系。实证结果表明：XGBoost 模型在事故严重程度分类任务中表现最优（准确率 83.8%，AUC=0.96），其 PDP 与 SHAP 解释性分析揭示了街景图特征，即道路基础设施，是影响事故严重程度的核心因素之一，且存在显著的空间异质性特征。同时，街景设施分析也证实了道路基础设施完善对降低事故风险的有效性。

（3）本研究以旧金山为例分析城市安全空间，基于危险系数空间热力图，得到道路与城市空间高危区域显著重合的结论；并且成功精准识别到旧金山 6 大高风险路段，呈现典型交通廊道风险集聚特征。结果说明，此评价体系能够辅助政策制定者和实践者合理布设城市道路基础设施、优化养护资源配置，从而降低高风险路段事故率及其严重程度。

6.2 创新点

（1）本研究创新性地横向对比了五大算法模型对于预测道路事故严重程度的表现，包括一个传统模型（GWR）与四个机器学习模型（XGBoost、逻辑回归、决策树、随机森林）。通过统一的数据预处理流程和评价指标，系统揭示了不同算法在预测能力及计算效率上的显著差异。研究不仅关注预测精度，还依靠混淆矩阵、PR 曲线与 ROC 曲线深入挖掘了各模型在事故严重程度分类中的特性差异。在得到 XGBoost 的最佳模型后，通过 PDP 分析与 SHAP 解释性分析的结合，得出了特征变量重要性的一致性验证，并通过地理信息系统成功应用了该模型。该创新对比体系为道路安全管理部门提供了算法选型依据，推动了道路安全检测的发展。

（2）本研究创新性地构建了多源数据融合的道路环境安全评价模型，首次实现城市街景图像与气象要素的跨维度耦合分析，形成以街景特征道路基础设施为主导，气象特征与环境为辅助的分析体系。技术层面，采用深度学习算法对海量街景图像进行语义分割，精准提取道路隔离栏、人行横道、交通标志等 9 类基础设施的空间分布特征；同时整合气象部门提供的能见度、气温、风速、气压、湿度数据，建立基于 GIS 平台的道路设施环境安全空间。研究实现了高风险道路的可视化热力图预警，强调了高风险路段的基础设施缺陷，为城市建设者提供了基础设施优化、气象预警辅助的策略，增强了道路安全治理的主观能动性。

6.3 展望

（1）当前基于 YOLO 架构的语义分割模型受限于 500 张自标注图像的小样本训练集，存在边缘模糊与细粒度特征捕捉不足的问题。除了提升标注精度与样本数量以外，在训练模型方面，

可通过多维数据融合策略，构建协同训练框架，采用 DeepLabv3+与 YOLO 双阶段集成架构，将目标检测置信度作为语义分割的注意力权重，实现检测-分割任务的协同优化。

（2）机器模型在本研究尚未充分利用道路环境的多维数据，可对天气、风向、事故描述文本等非结构化特征进行深度编码，开发多模型异构集成框架，将 Transformer 的预测结果作为 XGBoost 的衍生特征输入，同时对比树模型与图神经网络的融合效果。建立动态特征重要性评估机制，通过 SHAP 值分析优化特征组合策略。

（3）虽然 XGBoost 模型精确率高达 83%，但其 IV 级事故的误判率较高，且应用于旧金山场景时呈现显著类别偏移，完全缺失 I 级事故，这揭示了交通安全评价模型的场景适配挑战。后续研究可能需要增加训练数据样本减少过拟合，完善事故严重程度评级体系，并且建立地域特征转换矩阵以解决事故严重等级的地域差异。

（4）后续研究可将本研究的技术框架转换为应用接口，数据接入层通过标准化 API 集成多源传感器与政府开放数据；计算引擎层采用微服务架构，部署 YOLO 分割、XGBoost 预测、NeRF 数据增强等算法容器；可视化层实现从经纬度坐标到风险热力图的实时渲染，从而推动研究成果在自动驾驶高精地图安全校验等场景的落地应用。

参考文献

- [1] DUBEY A, NAIK N, PARIKH D, et al. Deep learning the city: Quantifying urban perception at a global scale[C]//Proceedings of the European Conference on Computer Vision. New York: Springer, 2016: 196-212.
- [2] 宁贵财, 康彩燕, 陈东辉, 等. 2005-2014 年我国不利天气条件下交通事故特征分析[J]. 干旱气象, 2016, 34(05): 753-762.
- [3] WIER M, WEINTRAUB J, HUMPHREYS E H, et al. An area-level model of vehicle-pedestrian injury collisions with implications for land use and transportation planning[J]. Accident Analysis and Prevention, 2009, 41(1): 137-145.
- [4] MIRANDA-MORENO L F, MORENCY P, EL-GENEIDY A M. The link between built environment, pedestrian activity and pedestrian-vehicle collision occurrence at signalized intersections[J]. Accident Analysis and Prevention, 2011, 43(5): 1624-1634.
- [5] HU Y J, CHEN L, ZHAO Z. How does street environment affect pedestrian crash risks? A link-level analysis using street view image-based pedestrian exposure measurement[J]. Accident Analysis & Prevention, 2024, 205: 107682. DOI:10.1016/j.aap.2024.107682.
- [6] RUNDLE A G, BADER M D M, RICHARDS C A, et al. Using Google Street View to Audit Neighborhood Environments[J]. American Journal of Preventive Medicine, 2011, 40(1): 94-100. DOI:10.1016/j.amepre.2010.09.034.
- [7] BILJECKI F, ITO K. Street view imagery in urban analytics and GIS: A review[J]. Landscape and Urban Planning, 2021, 215: 104217. DOI:10.1016/j.landurbplan.2021.104217.
- [8] HOU Y J, BILJECKI F. A comprehensive framework for evaluating the quality of street view imagery[J]. International Journal of Applied Earth Observation and Geoinformation, 2022, 115: 103094. DOI:10.1016/j.jag.2022.103094.
- [9] TIAN J J, WANG L Q, HE Y L, et al. Driving safety assessment and management for hidden danger segments of low-grade roads under adverse weather[C]//ZHANG L, MA J, LIU P, et al. CICTP 2019: Transportation in China-Connecting the World. New York: American Society of Civil Engineers, 2019: 3845-3854.
- [10] PHILIP A O, SARAVANAGURU R K. Multisource traffic incident reporting and evidence management in Internet of Vehicles using machine learning and blockchain[J]. Engineering Applications of Artificial Intelligence, 2023, 117: 105630. DOI:10.1016/j.engappai.2022.105630.
- [11] 胡启洲, 陆化普, 邓卫. 基于价值函数的城市道路交通安全测度模型[J]. 中国安全科学学报, 2010, 20(6): 45-50.
- [12] 崔洪军, 申晓静, 赵述捷, 等. 基于交通事故间距分布特征的事故黑点鉴定新方法[J]. 武汉理工大学学报, 2012, 34(2): 54-58.
- [13] 蒋宏, 方守恩, 陈雨人, 等. 基于空间自相关的城市道路事故多发点鉴别[J].

- 同济大学学报(自然科学版), 2013, 41(5): 664-669.
- [14] 王海, 李瑞敏. 缓冲区分析方法在事故多发点鉴别的应用研究[J].
公路工程, 2016, 41(1): 103-107.
- [15] 张琦, 陈红, 周继彪, 等. 道路开口对临近交叉口交通安全的影响[J].
浙江大学学报(工学版), 2021, 55(4): 720-726+756.
- [16] 洪皓珏. 基于多源数据挖掘技术的道路交通安全风险评估与对策研究[D].
金华: 浙江师范大学, 2019.
- [17] 寇敏, 张萌萌, 赵军学, 等. 道路交通安全风险辨识与分析方法综述[J].
交通信息与安全, 2022, 40(6): 22-32.
- [18] 张丽英, 裴韬, 陈宜金, 等. 基于街景图像的城市环境评价研究综述[J].
地球信息科学学报, 2019, 21(01): 46-58.
- [19] 吴炳剑, 高琳, 李衍志, 等. 结合生成对抗网络与混合注意力机制的街景图像语义分割[J].
软件导刊, 2024, 23(11): 187-192.
- [20] 李建, 邓彦杰, 高琳, 等. 公安视觉计算城市街景图像语义分割技术研究[J].
警察技术, 2024, (05): 42-45.
- [21] 杨文锦, 刘俐珂. 事故多发路段行车安全隐患检测与预警系统[J].
中外公路, 2012, 32(5): 286-289.
- [22] 陈熙, 郭迟, 万怡, 等. 面向动态隐患目标的车联网主动安全模型及系统实现[J].
小型微型计算机系统, 2015, 36(1): 22-26.
- [23] CHEN L C, ZHU Y, PAPANDREOU G, et al. Encoder-decoder with atrous separable convolution for semantic image segmentation[C]//Proceedings of the European Conference on Computer Vision. Berlin: Springer, 2018: 801-818.
- [24] ZHANG H, DANA K, SHI J, et al. Context Encoding for Semantic Segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE, 2018: 7151-7160.
- [25] AITKIN M. A general maximum likelihood analysis of overdispersion in generalized linear models[J]. Statistics and Computing, 1996, 6: 251-262. DOI:10.1007/BF00140869.
- [26] HOSMER D W Jr, LEMESHOW S, STURDIVANT R X. Applied logistic regression[M]. 3rd ed. Hoboken: John Wiley & Sons, 2013.
- [27] CIPRIANO C, NOCE S, MEREU S, et al. Algorithms going wild: A review of machine learning techniques for terrestrial ecology[J]. Ecological Modelling, 2025, 506: 111164. DOI:10.1016/j.ecolmodel.2025.111164.
- [28] QUINLAN J R. Induction of decision trees[J]. Machine Learning, 1986, 1: 81-106. DOI:10.1007/BF00116251.
- [29] BREIMAN L. Random forests[J]. Machine Learning, 2001, 45(1): 5-32. DOI:10.1023/A:1010933404324.
- [30] CHEN T, GUESTRIN C. XGBoost: A scalable tree boosting system[C]//Proceedings of the 22nd

- ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16). New York, NY, USA: ACM, 2016: 785-794. DOI:10.1145/2939672.2939785.
- [31] MOOSAVI S, SAMAVATIAN M H, PARTHASARATHY S, et al. A countrywide traffic accident dataset[DB/OL]. (2019-06-13)[2025-03-13]. <https://arxiv.org/abs/1906.05409>.
- [32] MOOSAVI S, SAMAVATIAN M H, PARTHASARATHY S, et al. Accident risk prediction based on heterogeneous sparse data: New dataset and insights[C]//Proceedings of the 27th ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems. New York, NY, USA: ACM, 2019: 1-10. DOI:10.1145/3347146.3359357.
- [33] U.S. DEPARTMENT OF TRANSPORTATION. KABCO Injury Classification Scale and Definitions[S/OL]. Washington, D.C.: U.S. Department of Transportation, 2025[2025-04-30]. <https://highways.dot.gov/media/20141>.
- [34] 梁龙飞, 张秀媛. 道路交通事故与道路交通设备关系和改进方案[J]. 科技创新与生产力, 2025, 46(02): 36-39+43.
- [35] HALL J D, MADSEN J M. Can behavioral interventions be too salient? Evidence from traffic safety messages[J]. Science, 2022, 376: eabm3427. DOI:10.1126/science.abm3427.
- [36] 吴浩文. 基于驾驶员动态视野的公路空间视觉感受指标提取研究[D]. 长安大学, 2023. DOI:10.26976/d.cnki.gchau.2023.000601.

谢辞

2025 年 5 月，我度过了大学期间最繁忙的一个月。在这一个月里，我无暇去青睐平日喜爱的各种娱乐活动，而只能在脑海里思索与回忆。我由于内向而不善交友，回忆大学期间的点点滴滴，发现忆起的一切，无非都有关那几个瞬间和几个人。青春似乎实在乏善可陈就临到末尾，至于论文中值得致谢的，就更加寥寥无几了。

首先在此感谢我的父母，他们虽然没有较高的文化，却赋予了我意蕴深远又独一无二的姓名，也成为了我重要的启蒙老师；他们虽然没有广阔的人脉，但当我给他们看到各种糟糕的成绩单时，从来都是耐着性子鼓励我，学习也因此从来不是我的敌人。父母在我生命中唯一一次打骂我，是因为我在幼儿园偷了一块可以伸缩的沾满闪粉的橡皮。

在曾经年轻气盛的时候，我常因为他们一些落后观念而轻视他们，将他们的谨慎视作迂腐，把生活的褶皱理解成怯懦。在大学的后半段，教科书中里的理想主义被现实磨平时，我才开始为这些想法忏悔，因为人生并不是仅靠观念铸就的，还有很多现实的顾虑和拖累，那都是我不曾体会过的艰辛。正是他们奉送半生的心血的至高点铸就了我人生的起点，也因此能够在本科毕业时支持我继续升学甚至留学的选择。我再不应站在他们用血汗夯实的路基上，对着星空妄议尘埃。

我尤其感谢妈妈，她就像一棵把年轮刻进年轮的树，承受过太多压力都用树皮一层层的包裹住，却把所有断枝磨成渡我的舟楫，始终相信一切美好的事情都会在她不成器的儿子身上发生，忙忙碌碌又甘之如饴。只是可惜，我终究没能长成她愿景中金光璀璨的模样，就像父母始终读不懂我的观点与论文。可这又有什么关系呢？当我用语义分割割出一条条道路的时候，分明看见二十年前小城的烈日下，那对把自行车蹬得火星四溅的夫妻，正飞驰在坑洼的水泥道路上畅想着未来，正如我有同样的畅想。那些留在水泥路上未曾兑现的承诺，终将被一层层沥青覆盖去，不论他们未来如何看待我，我都感激他们对我的降生。

我要感谢余博导师，我时常在想，要是早些遇到余老师的课题组，我可能不会再选择留学这条路。我是一个懒惰的人，尽管很早就想了解 AI，但自己却迟迟没有动力。余老师的课题为我提供了一个关键的机会，督促我主动实现我自己的愿望。余老师是非常负责的导师，每周的例会上，都会对大家的汇报提出详实而富有建设性的意见，也从不吝惜批评与表扬。在余老师的指导监督下，我才对论文的进展有了合理的预估与推进。

我还要感谢黄国滔学长。他引导我接触了 AI 的新时代，从机器学习到语义分割，很多细节上的问题无从寻找解答，是学长在我茫然无措的时候，一针见血地为我指明方向。这篇论文就像是一本博览会的护照，记载着所有我从学习到熟练运用 AI 的全过程，也给予我足够信心去深入了解每个模型的具体算法。在高中毕业的多年以后，我也终于明白了地理书中的 GIS 到底是何方神圣。论文绘图时，每一张图学长都以高标准要求我，尤其是第五章的城市安全空间热力图，指导了我八次有余，才有了文中信息量与美观兼备的最终版本。当我半夜交的初稿，隔天就看到他密密麻麻的批注时，我发自内心地震撼且感动。在我的学生生涯中，好像再没有谁为我自己的工作任务如此上心过。若非有学长如此的负责指导，就不可能诞生这篇重心明确，内容逻辑顺畅的论文。

同样，我要感谢一路以来始终支持陪伴我的其他家人与朋友，感谢带领我适应大学生活的 ASCE。是你们的陪伴让我熬过了那些迷茫与纠结的时光，是你们的鼓励与支持让我得以走到今天。你们的付出，我铭记于心。

在交初稿的前一晚，奋笔写作的时候尚万籁俱寂，但是躺在黑暗中将要入睡的那一刻，窗外竟立刻传来小鸟的叫声，时间恰好是凌晨四点。我竟一瞬间困意全消，而舍不得阖眼了。这般时辰与邂逅，倒像是造物主特意安排的玄机，教我近乎痴迷地感受到一股神性。大学以来已经许久未曾发生这样感性的时刻，我于是立刻下床写了这篇致谢，同时感激自己还能感受这世界。

最后，感谢我在这象牙塔中那些黄金般又一文不值的青春岁月，能与这份期望双向奔赴，虽渺小如沧海一粟，但于我而言已经足够幸运。很多人说，本科毕业象征着青春的结束，但是，我想，这里应该是开始。

装
订
线